

Problema 1

Usando el teorema de *Gershgorin* deduce estimaciones de los eigenvalores de

$$\mathbf{A} = \begin{bmatrix} 8 & 1 & 0 \\ 1 & 4 & \epsilon \\ 0 & \epsilon & 1 \end{bmatrix}, \quad (1)$$

El teorema de Gershgorin nos dice que existen 3 discos con centros en los puntos

$$\mathbf{a}_{11} = 8, \quad \mathbf{a}_{22} = 4 \quad \text{y} \quad \mathbf{a}_{33} = 1 \quad (2)$$

del plano complejo con radios

$$\mathbf{R}_1 = |1|, \quad \mathbf{R}_2 = |1| + |\epsilon| \quad \text{y} \quad \mathbf{R}_3 = |\epsilon| \quad (3)$$

De modo que los 3 discos de Gershgorin son de la forma $D(a_{11}, R_1)$, $D(a_{22}, R_2)$ y $D(a_{33}, R_3)$. Consideraremos a estos discos abiertos, sin su frontera. A continuaci  n graficamos los discos para diferentes valores de ϵ .




Figura 1: Discos de Gershgorin

Aplicando la segunda parte del enunciado del teorema de Gershgorin que dice **“Adem  s, si n de estos discos forman un dominio conexo, disjunto de los otros m discos, entonces hay exactamente n eigenvalores en ese dominio.”**, podemos estudiar diferentes casos dependiendo del n  mero de intersecciones tengan los discos. Algo importante que mencionar antes de hablar de estimaciones de eigenvalores es que siendo \mathbf{A} una matriz sim  trica, entonces los eigenvalores son reales, por lo que solo estar  n en el eje-x de las gr  ficas anteriores.

- **Ninguna intersecci  n**, $0 < \epsilon < 1$: La segunda parte del teorema que mencionamos antes aplicada a $n = 1$ nos asegura que en cada dominio conexo, en este caso cada disco

individual, se encuentran exactamente $n = 1$ eigenvalores exactamente. Por lo tanto existen 3 eigenvalores que podemos estimar como

$$\lambda_1 \in (7, 8), \quad \lambda_2 \in (3 - |\epsilon|, 5 + |\epsilon|) \quad y \quad \lambda_3 \in (1 - |\epsilon|, 1 + |\epsilon|) \quad (4)$$

- **Una intersecci  n**, $1 < \epsilon < 2$: Ahora podemos aplicar el teorema para un dominio conexo de $n = 2$ discos de Gershgorin. De modo el dominio conexo de los discos $D(a_{22}, R_2)$ y $D(a_{33}, R_3)$ contiene exactamente 2 eigenvalores y el disco restante contiene 1 eigenvalor. Por lo tanto existen 3 eigenvalores que podemos estimar como

$$\lambda_1 \in (7, 9) \quad y \quad \lambda_2, \lambda_3 \in (1 - |\epsilon|, 5 + |\epsilon|) \quad (5)$$

- **Dos intersecciones**, $2 < \epsilon$: En este caso tenemos un dominio conexo de $n = 3$ discos de Gershgorin. De modo que este dominio conexo de los discos $D(a_{11}, R_1)$, $D(a_{22}, R_2)$ y $D(a_{33}, R_3)$ contiene exactamente 3 eigenvalores. Por lo tanto existe 3 eigenvalores que podemos estimar como

$$\lambda_1, \lambda_2, \lambda_3 \in (1 - |\epsilon|, \max(5 + |\epsilon|, 9)) \quad (6)$$

Dando estimaciones para los eigenvalores de **A**.

Problema 2

Implementa la iteraci  n QR con shift. Apl  cala a la matriz A del Ejercicio 1 con $\epsilon = 10^N$, para $N = 1, \dots, 5$.

Presentamos un extracto de la implementaci  n del **Algoritmo QR** hecho en python.

Algorithm 1: Algoritmo QR.. Implementado en el archivo **eigenvalues.py**.

```
# To Hessenberg form
A_k = hessenberg_form(A)

for kdx in range(0, iterations):
    # Pick a shift
    mu = A_k[m - 1, m - 1]

    # Calculate QR factorization
    (Q, R) = qr_factorization(A_k - mu * np.identity(m))

    # Multiply by Q from the right
    A_k = R @ Q + mu * np.identity(m)
```

```
# Calculate eigenvectors
Q_k = Q_k @ Q
```

Aplicandolo a la matriz A para los diferentes valores de ϵ mencionados, obtuvimos el siguiente conjunto de eigenvalores y eigenvectores,

	Eigenvalores	Eigenvectores
$\epsilon = 10^1$	$\lambda_1 = -7.639, \lambda_2 = 8.236, \lambda_3 = 12.403$	$V = \begin{bmatrix} 0.042 & -0.911 & 0.411 \\ 0.653 & -0.287 & -0.701 \\ 0.756 & 0.298 & 0.583 \end{bmatrix}$
$\epsilon = 10^2$	$\lambda_1 = -97.516, \lambda_2 = 7.999, \lambda_3 = 102.517$	$V = \begin{bmatrix} -0.007 & 1.000 & 0.008 \\ -0.702 & 0.001 & -0.712 \\ -0.712 & -0.010 & 0.702 \end{bmatrix}$
$\epsilon = 10^3$	$\lambda_1 = -997.502, \lambda_2 = 8.000, \lambda_3 = 1002.502$	$V = \begin{bmatrix} 0.001 & 1.000 & 0.001 \\ 0.707 & 0.000 & -0.708 \\ 0.708 & -0.001 & 0.707 \end{bmatrix}$
$\epsilon = 10^4$	$\lambda_1 = -9997.500, \lambda_2 = 8.000, \lambda_3 = 10002.500$	$V = \begin{bmatrix} 0.000 & 1.000 & -0.000 \\ 0.707 & 0.000 & 0.707 \\ 0.707 & -0.000 & -0.707 \end{bmatrix}$
$\epsilon = 10^5$	$\lambda_1 = -99997.500, \lambda_2 = 8.000, \lambda_3 = 100002.500$	$V = \begin{bmatrix} 0.000 & 1.000 & -0.000 \\ 0.707 & 0.000 & 0.707 \\ 0.707 & -0.000 & -0.707 \end{bmatrix}$

Problema 3

Determina todos los eigenvalores y eigenvectores de una matriz de Householder.

Una matriz de Householder es de la forma,

$$\mathbf{H} = \mathbf{I} - 2\mathbf{u}\mathbf{u}^t \quad (7)$$

siendo $\mathbf{u} \in \mathbb{R}^m$ un vector unitario, osea que $\mathbf{u}^t\mathbf{u} = 1$.

Multiplicamos el vector \mathbf{u} por la matriz \mathbf{H} ,

$$\mathbf{H}\mathbf{u} = \mathbf{u} - 2(\mathbf{u}\mathbf{u}^t)\mathbf{u} = \mathbf{u} - 2\mathbf{u}(\mathbf{u}^t\mathbf{u}) = \mathbf{u} - 2\mathbf{u} = -\mathbf{u}, \quad (8)$$

de modo que el eigenvalor asociado al primer eigenvector $\mathbf{v}_1 = \mathbf{u}$ es $\lambda_1 = -1$.

Sea $\mathbf{v} \in \mathbb{R}^m$ un vector ortogonal al vector \mathbf{u} , osea que $\mathbf{v}^t\mathbf{u} = 0$. Tenemos que,

$$\mathbf{H}\mathbf{v} = \mathbf{v} - 2(\mathbf{u}\mathbf{u}^t)\mathbf{v} = \mathbf{v} - 2\mathbf{u}(\mathbf{u}^t\mathbf{v}) = \mathbf{v} - 2\mathbf{u} \cdot 0 = \mathbf{v}. \quad (9)$$

De modo que el eigenvalor asociado al segundo eigenvector $\mathbf{v}_2 = \mathbf{v}$ es $\lambda_2 = +1$.

Notemos que como \mathbb{R}^m es un espacio vectorial de dimensi  n finita \mathbf{m} , y siendo \mathbf{U}^\perp el espacio de vectores ortogonales a \mathbf{u} , entonces \mathbf{U}^\perp es un espacio de dimensi  n $\mathbf{m} - 1$. Esto se deduce aplicando el teorema de rango y nulidad al operador lineal \mathbf{u}^t .

Y como vimos con la ecuaci  n (9), cualquier vector en \mathbf{U}^\perp es un eigenvector y m  s a  n existe una base ortogonal de \mathbf{U}^\perp de eigenvectores $\mathbf{v}_2 = \mathbf{v}, \mathbf{v}_3, \dots, \mathbf{v}_m$ que tienen el eigenvalor asociado $\lambda_2 = +1$.

Encontrando todos los eigenvalores y eigenvectores de la transformaci  n \mathbf{H} .

Problema 4

Demuestra que no es posible construir la transformaci  n de similaridad del teorema de Schur con un n  mero finito de transformaciones de similaridad de Householder.

Lo que primero debemos considerar es la forma en que estamos atacando el problema de encontrar los eigenvalores de cierta matrix $\mathbf{A} \in \mathbb{R}^{m \times m}$ utilizando el **algoritmo QR**. Estamos aproximando iterativamente la **descomposici  n de Schur** $\mathbf{A} = \mathbf{Q}^{-1}\mathbf{U}\mathbf{Q}$ y como paso previo podemos (no es necesario) reducir a una matriz similar $\mathbf{A}' = \mathbf{Q}^{-1}\mathbf{A}\mathbf{Q}$ en forma de **Hessenberg** (tridiagonal si \mathbf{A} es hermitiana o triangular superior con la superdiagonal inferior si no es hermitiana).

Para calcular la forma de **Hessenberg** aplicamos un n  mero finito de veces una transformaci  n (reflexi  n) de Householder para ir agregando ceros en cada paso, obteniendo una matriz similar a \mathbf{A} , que tiene los mismos eigenvalores.

Si fuera posible que con transformaciones de similaridad de Householder obtuvi  ramos la **descomposici  n de Schur** en n  mero de finito de pasos, obtendr  amos una matriz $\mathbf{A}' = \mathbf{H}_k^{-1}\mathbf{A}\mathbf{H}_k$ que contiene a los eigenvalores de \mathbf{A} en su diagonal. Hemos encontrado las raices del polinomio caracter  stico de \mathbf{A} , que son los mismos eigenvalores, utilizando solo operaciones elementales de suma, resta, multiplicaci  n, divisi  n y raices. Notemos que el polinomio caracter  stico de \mathbf{A} es de grado m .

Si tuvi  ramos una matriz con $m \geq 5$ habr  amos calculado expl  citamente, como mencionamos antes, todas las raices de un polinomio de grado m . Esto no es posible pues contradice directamente el resultado del **Teorema de Abel-Ruffini**, que asegura que no es posible dar una formula para calcular las raices de un polinomio de grado 5 o mayor utilizando solo las

operaciones elementales mencionadas antes.

Con esto demostramos que no es posible dar la descomposici  n de **Teorema de Schur** utilizando un n  mero finito de transformaciones de similaridad de Householder. Tambi  n hemos visto la raz  n m  s importante por la que se debe tratar con algoritmos iterativos para calcular eigenvalores.

Problema 5

   Qu   pasa si aplicas la iteraci  n QR sin shift a una matriz ortogonal ?

Sea $\mathbf{A} \in \mathbb{R}^{m \times m}$ una matriz ortogonal. Estudiemos la forma de su factorizaci  n **QR**. Existe una factorizaci  n de la forma $\mathbf{A} = \mathbf{QR}$ siendo \mathbf{Q} una matriz unitaria y \mathbf{R} una matriz triangular superior, teniendo que

$$\begin{bmatrix} | & | & \cdots & | \\ a_1 & a_2 & \cdots & a_m \\ | & | & \cdots & | \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ q_1 & q_2 & \cdots & q_m \\ | & | & \cdots & | \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ & r_{22} & & \vdots \\ & & \ddots & \\ & & & r_{mm} \end{bmatrix} \quad (10)$$

siendo $\mathbf{a}_i, \mathbf{q}_i$, para $i \in \{1, 2, \dots, m\}$, los vectores columna de las matrices \mathbf{A} y \mathbf{Q} , respectivamente. Tambi  n podemos representar la factorizaci  n con las siguientes ecuaciones,

$$\begin{aligned} a_1 &= r_{11}q_1 \\ a_2 &= r_{12}q_1 + r_{22}q_2 \\ a_3 &= r_{13}q_1 + r_{23}q_2 + r_{33}q_3 \\ &\vdots \\ a_m &= r_{1m}q_1 + r_{2m}q_2 + \cdots + r_{mm}q_m \end{aligned}$$

Ya que \mathbf{Q} es una matriz unitaria, las columnas \mathbf{q}_i forman una base ortonormal de \mathbf{R}^m . Y por las ecuaciones anteriores, sabemos que el espacio que generan q_1, q_2, \dots, q_m es igual al espacio generado a_1, a_2, \dots, a_m por las columnas de \mathbf{A} .

Puesto que \mathbf{A} es una matriz ortogonal, los vectores $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m$ forman una base ortogonal de \mathbf{R}^m , por lo que una descomposici  n **QR** de \mathbf{A} podr  a ser

$$\hat{\mathbf{Q}} = \begin{bmatrix} \frac{a_1}{\|a_1\|} & \frac{a_2}{\|a_2\|} & \cdots & \frac{a_m}{\|a_m\|} \\ \vdots & \vdots & \ddots & \vdots \end{bmatrix}, \quad \hat{\mathbf{R}} = \begin{bmatrix} \|a_1\| & & & \\ & \|a_2\| & & \\ & & \ddots & \\ & & & \|a_m\| \end{bmatrix} \quad (11)$$

De nuestro conocimiento previo sobre el c  culo de la factorizaci  n **QR** utilizando el **proceso de Gram–Schmidt**, sabemos que obtendr  amos exactamente la misma factorizaci  n $\hat{\mathbf{Q}}, \hat{\mathbf{R}}$.

Esto anterior pues en el primer paso tomar  amos $q_1 = \frac{a_1}{\|a_1\|}$. En el paso i tomar  amos el vector \mathbf{a}_i , le restar  amos todas la proyecciones respecto a los vectores anteriores $\mathbf{a}_i - \sum_{j=1}^{i-1} (a_i \cdot q_j) q_j$ y al final normalizamos el vector resultando. Notemos que en el segundo paso la proyecci  n $(a_2 \cdot q_1)$ ser  a cero, por ser \mathbf{a}_1 y \mathbf{a}_2 ortogonales, por lo que $q_2 = \frac{a_2}{\|a_2\|}$. Inductivamente demostramos que $q_i = \frac{a_i}{\|a_i\|}$.

Finalmente notaremos que durante la primera iteraci  n del **Algoritmo QR sin shift**, la siguiente estimaci  n \mathbf{A}_k ser  a exactamente igual a \mathbf{A} puesto que

Algorithm 2: Algoritmo QR

A_0 &:= A

Paso 1 :

QR := A_0

Calcula factorizacion QR

Paso 2 :

A_1 := RQ = QR = A

Las matrices diagonales conmutan

Por lo que en cualquier iteraci  n subsecuente tendr  amos que $A_k := A$.